1. Giriş

Finansal teknolojilerin ve dijital ödeme sistemlerinin hızlı gelişimi ile birlikte kredi kartı kullanımı dünya genelinde önemli ölçüde artmıştır. Kredi kartları kullanıcılar için hızlı ve pratik bir ödeme yöntemi sunarken, aynı zamanda finansal dolandırıcılık faaliyetlerinin de artmasına neden olmaktadır. Kredi kartı dolandırıcılığı bankalar, finans kuruluşları ve kullanıcılar için ciddi ekonomik kayıplara yol açabilen önemli bir güvenlik problemidir. Bu nedenle finans sektöründe dolandırıcılık işlemlerinin mümkün olan en erken aşamada tespit edilmesi büyük önem taşımaktadır.

Kredi kartı dolandırıcılığı tespit problemi makine öğrenmesi açısından oldukça zorlu bir sınıflandırma problemidir. Bunun temel nedeni, gerçek dünya işlem verilerinde dolandırıcılık işlemlerinin toplam işlemler içerisinde çok küçük bir orana sahip olmasıdır. Bu durum veri setinin yüksek derecede dengesiz (imbalanced) olmasına yol açar. Dolandırıcılık işlemleri toplam işlemlerin yalnızca küçük bir yüzdesini oluştururken, normal işlemler veri setinin büyük çoğunluğunu temsil eder. Bu nedenle klasik sınıflandırma problemlerinde sıklıkla kullanılan accuracy (doğruluk) metriği tek başına model performansını değerlendirmek için yeterli değildir. Örneğin tüm işlemleri “normal işlem” olarak sınıflandıran bir model yüksek doğruluk elde edebilir ancak dolandırıcılık işlemlerini tespit edemediği için pratikte kullanışlı olmayacaktır.

Son yıllarda makine öğrenmesi yöntemleri dolandırıcılık tespiti problemlerinde yaygın olarak kullanılmaktadır. Bu yöntemler büyük miktarda işlem verisini analiz ederek dolandırıcılık davranışlarına ait örüntüleri öğrenebilmekte ve yeni işlemler üzerinde otomatik tahminler üretebilmektedir. Özellikle Random Forest, Logistic Regression, Gradient Boosting, XGBoost ve LightGBM gibi algoritmalar finansal veri analizi ve anomali tespiti problemlerinde güçlü performans göstermektedir.

Ancak dolandırıcılık tespiti problemlerinde yalnızca model doğruluğunu artırmak yeterli değildir. Gerçek finansal sistemlerde farklı türde sınıflandırma hatalarının maliyetleri birbirinden farklıdır. Bir dolandırıcılık işleminin model tarafından fark edilmemesi (False Negative) finans kuruluşları için doğrudan finansal kayıplara neden olabilir. Buna karşılık normal bir işlemin yanlışlıkla dolandırıcılık olarak işaretlenmesi (False Positive) müşteri deneyimini olumsuz etkileyebilir ve gereksiz işlem engellemelerine yol açabilir. Bu nedenle dolandırıcılık tespit sistemlerinde maliyet duyarlı (cost-sensitive) yaklaşımlar önemli bir rol oynamaktadır.

Bu çalışmada kredi kartı dolandırıcılığı tespit problemi maliyet duyarlı bir makine öğrenmesi yaklaşımı kullanılarak ele alınmıştır. Çalışmada öncelikle **Random Forest** modeli baseline model olarak eğitilmiş ve modelin performansı değerlendirilmiştir. Ardından sınıflandırma karar eşiği değiştirilerek maliyet tabanlı eşik optimizasyonu **(cost-based threshold optimization)** uygulanmıştır. Bu yaklaşımda toplam maliyet aşağıdaki şekilde hesaplanmaktadır:

Total Cost = FP × FP_cost + FN × FN_cost

Burada:

- FP (False Positive): Normal işlemin yanlışlıkla dolandırıcılık olarak sınıflandırılması
- FN (False Negative): Dolandırıcılık işleminin model tarafından kaçırılması

Bu çalışmada dolandırıcılık işleminin kaçırılmasının maliyeti daha yüksek olduğu için FN maliyeti FP maliyetinden daha büyük olarak tanımlanmıştır. Bu sayede modelin dolandırıcılık işlemlerini yakalama başarısı artırılmaya çalışılmıştır.

Random Forest modeli için eşik optimizasyonu gerçekleştirildikten sonra model performansı diğer makine öğrenmesi algoritmaları ile karşılaştırılmıştır. Bu kapsamda **Logistic Regression, Gradient Boosting, XGBoost ve LightGBM** algoritmaları eğitilmiş ve performansları karşılaştırılmıştır. Model değerlendirmesinde dengesiz veri setleri için daha uygun olan aşağıdaki metrikler kullanılmıştır:

- Precision
- Recall
- PR-AUC (Precision-Recall Area Under Curve)
- Cost-based evaluation

Bu metrikler sayesinde modellerin dolandırıcılık işlemlerini yakalama başarısı ve yanlış alarm oranları daha doğru bir şekilde değerlendirilmiştir.

Model sonuçlarının daha iyi yorumlanabilmesi için ayrıca feature importance analizi yapılmıştır. Bu analiz sayesinde dolandırıcılık tespitinde en etkili olan değişkenler belirlenmiştir. Bunun yanında modelin karar mekanizmasını daha iyi anlamak amacıyla SHAP (SHapley Additive exPlanations) yöntemi kullanılarak model açıklanabilirliği sağlanmıştır.

Elde edilen sonuçların daha anlaşılır ve görsel olarak analiz edilebilmesi amacıyla Tableau kullanılarak interaktif bir analiz paneli (dashboard) geliştirilmiştir. Bu dashboard üzerinde model karşılaştırmaları, karar eşiği ile maliyet arasındaki ilişki, precision–recall analizi ve feature importance sonuçları görselleştirilmiştir.

Bu çalışma kapsamında geliştirilen yaklaşım sayesinde farklı makine öğrenmesi modellerinin dolandırıcılık tespit performansları karşılaştırılmış ve maliyet açısından en uygun model belirlenmiştir. Ayrıca karar eşiğinin doğru seçilmesinin dolandırıcılık tespit sistemlerinin performansı üzerinde önemli bir etkisi olduğu gösterilmiştir.

2. Veri Seti (Dataset Description)

Bu çalışmada kredi kartı dolandırıcılığı tespit problemi için kamuya açık olarak sunulan Credit Card Fraud Detection veri seti kullanılmıştır. Veri seti Avrupa'daki kart sahipleri tarafından gerçekleştirilen kredi kartı işlemlerini içermektedir ve gerçek dünya finansal işlem verilerini temsil etmektedir. Veri seti toplam 284,807 işlem içermekte olup bu işlemlerin yalnızca 492 tanesi dolandırıcılık işlemi olarak etiketlenmiştir. Bu durum veri setinin oldukça dengesiz (imbalanced) bir yapıya sahip olduğunu göstermektedir. Dolandırıcılık işlemleri veri setinin yaklaşık %0.172'sini oluşturmaktadır.

Veri setinde toplam 31 değişken bulunmaktadır. Bu değişkenlerden 30 tanesi bağımsız değişken (feature) ve 1 tanesi hedef değişken (target variable) olarak kullanılmaktadır. Hedef değişken Class olarak adlandırılmıştır ve ikili bir sınıflandırma yapısına sahiptir:

- Class = 0 → Normal işlem
- Class = 1 → Dolandırıcılık işlemi

Veri setinde bulunan değişkenlerin büyük bir kısmı güvenlik ve gizlilik nedenleriyle Principal Component Analysis (PCA) yöntemi kullanılarak dönüştürülmüş ve anonimleştirilmiştir. Bu nedenle veri setinde yer alan özellikler V1, V2, V3, ..., V28 şeklinde isimlendirilmiştir. PCA dönüşümü sayesinde kullanıcıların finansal bilgileri korunurken, modelleme için gerekli olan veri yapısı korunmuştur.

```python
import numpy as np
import pandas as pd

from sklearn.model_selection import train_test_split
from sklearn.metrics import (
     classification_report, confusion_matrix,
     average_precision_score, precision_recall_curve
)
from sklearn.ensemble import RandomForestClassifier
DATA_PATH = "creditcard.csv"
TARGET_COL = "Class"
TEST_SIZE = 0.30
RANDOM_STATE = 42
```

```python
df = pd.read_csv(DATA_PATH)
df.head()
```

	Time	V1	V2	V3	V4	V5	V6	V7	V8	V9	...	V21	V22	V23	V24	
0	0.0	-1.359807	-0.072781	2.536347	1.378155	-0.338321	0.462388	0.239599	0.098698	0.363787	...	-0.018307	0.277838	-0.110474	0.066928	0.1
1	0.0	1.191857	0.266151	0.166480	0.448154	0.060018	-0.082361	-0.078803	0.085102	-0.255425	...	-0.225775	-0.638672	0.101288	-0.339846	0.
2	1.0	-1.358354	-1.340163	1.773209	0.379780	-0.503198	1.800499	0.791461	0.247676	-1.514654	...	0.247998	0.771679	0.909412	-0.689281	-0.3
3	1.0	-0.966272	-0.185226	1.792993	-0.863291	-0.010309	1.247203	0.237609	0.377436	-1.387024	...	-0.108300	0.005274	-0.190321	-1.175575	0.6
4	2.0	-1.158233	0.877737	1.548718	0.403034	-0.407193	0.095921	0.592941	-0.270533	0.817739	...	-0.009431	0.798278	-0.137458	0.141267	-0.2

5 rows × 31 columns

Veri setinde PCA dönüşümüne tabi tutulmamış iki adet değişken bulunmaktadır:

- Time: İşlemin veri setindeki ilk işlemden itibaren geçen süreyi (saniye cinsinden) ifade etmektedir.
- Amount: İşlemin parasal değerini göstermektedir.

Dolandırıcılık tespiti problemlerinde veri setinin dengesiz yapısı model eğitimi ve değerlendirmesi açısından önemli zorluklar oluşturabilir. Bu nedenle veri seti üzerinde çalışılırken stratified train-test split yöntemi kullanılmıştır.

Bu yöntem sayesinde eğitim ve test veri setlerinde dolandırıcılık işlemlerinin oranı korunmuştur. Çalışmada veri seti %70 eğitim verisi ve %30 test verisi olacak şekilde bölünmüştür.

Veri setinin dengesiz yapısı nedeniyle model performansını değerlendirmek için doğruluk (accuracy) metriği tek başına yeterli değildir. Bu nedenle çalışmada model performansını daha doğru değerlendirebilmek için Precision, Recall ve PR-AUC gibi metrikler kullanılmıştır. Ayrıca dolandırıcılık işlemlerinin kaçırılmasının finansal açıdan daha büyük maliyetlere yol açabileceği göz önünde bulundurularak maliyet duyarlı bir değerlendirme yaklaşımı uygulanmıştır.

Bu çalışmada kullanılan veri seti, dolandırıcılık tespiti alanında yaygın olarak kullanılan benchmark veri setlerinden biri olup, farklı makine öğrenmesi algoritmalarının performanslarını karşılaştırmak için uygun bir yapı sunmaktadır.

3. Metodoloji (Methodology)

Bu çalışmada kredi kartı dolandırıcılığı tespit problemi için farklı makine öğrenmesi algoritmaları kullanılmış ve modeller maliyet duyarlı bir yaklaşım ile değerlendirilmiştir. Çalışma kapsamında veri hazırlama, model eğitimi, karar eşiği optimizasyonu ve model karşılaştırması aşamalarından oluşan bir yöntem uygulanmıştır.

3.1 Veri Hazırlama

Model eğitimi öncesinde veri seti eğitim ve test veri setlerine ayrılmıştır. Veri setinin dengesiz yapısı göz önünde bulundurularak stratified sampling yöntemi kullanılmıştır. Bu yöntem sayesinde dolandırıcılık işlemlerinin eğitim ve test veri setlerinde benzer oranlarda dağıtılması sağlanmıştır.

Veri seti aşağıdaki oranlarda bölünmüştür:

- %70 Eğitim verisi
- %30 Test verisi

Eğitim veri seti modellerin öğrenmesi için kullanılırken, test veri seti modellerin performansını değerlendirmek amacıyla kullanılmıştır.

3.2 Baseline Model: Random Forest

Çalışmada ilk olarak Random Forest algoritması kullanılarak bir baseline model oluşturulmuştur. Random Forest algoritması karar ağaçları temelli bir ensemble öğrenme yöntemidir ve özellikle tabular veri üzerinde güçlü performans göstermektedir.

Random Forest modeli aşağıdaki parametrelerle eğitilmiştir:

- n_estimators = 300
- class_weight = balanced_subsample
- random_state = 42

Class weight parametresi kullanılarak veri setindeki sınıf dengesizliğinin model üzerindeki etkisi azaltılmaya çalışılmıştır.

Model eğitildikten sonra test veri seti üzerinde tahminler yapılmış ve model performansı değerlendirilmiştir.

3.3 Model Değerlendirme Metrikleri

Dolandırıcılık tespiti problemi yüksek derecede dengesiz bir veri setine sahip olduğu için doğruluk (accuracy) metriği model performansını değerlendirmek için yeterli değildir. Bu nedenle çalışmada aşağıdaki metrikler kullanılmıştır:

- Precision: Modelin dolandırıcılık olarak tahmin ettiği işlemlerin ne kadarının gerçekten dolandırıcılık olduğunu gösterir.
- Recall: Gerçek dolandırıcılık işlemlerinin model tarafından ne kadarının doğru şekilde tespit edildiğini gösterir.
- PR-AUC (Precision-Recall Area Under Curve): Precision ve Recall arasındaki ilişkiyi özetleyen performans metriğidir.

Bu metrikler dolandırıcılık tespiti gibi dengesiz veri setlerinde model performansını daha doğru bir şekilde değerlendirmeye olanak sağlar.

3.4 Cost-Based Threshold Optimization

Kredi kartı dolandırıcılığı tespiti problemlerinde farklı hata türlerinin maliyetleri birbirinden farklıdır. Bir dolandırıcılık işleminin model tarafından kaçırılması (False Negative) finans kuruluşları için doğrudan finansal kayıplara yol açabilir. Buna karşılık normal bir işlemin yanlışlıkla dolandırıcılık olarak işaretlenmesi (False Positive) müşteri deneyimini olumsuz etkileyebilir.

Bu nedenle çalışmada maliyet duyarlı bir eşik optimizasyonu yaklaşımı uygulanmıştır. Toplam maliyet aşağıdaki formül kullanılarak hesaplanmıştır:

Total\ Cost = FP \times FP_cost + FN \times FN_cost

Bu çalışmada:

- FP cost = 10
- FN cost = 500

Olarak belirlenmiştir.

Modelin farklı karar eşikleri için performansı incelenmiş ve toplam maliyeti minimize eden optimal karar eşiği belirlenmiştir.

3.5 Model Karşılaştırması

Random Forest modeli için eşik optimizasyonu gerçekleştirildikten sonra model performansı diğer makine öğrenmesi algoritmaları ile karşılaştırılmıştır. Bu kapsamda aşağıdaki algoritmalar kullanılmıştır:

- Logistic Regression
- Random Forest
- Gradient Boosting
- XGBoost
- LightGBM

Her model eğitim veri seti üzerinde eğitilmiş ve test veri seti üzerinde değerlendirilmiştir. Modeller Precision, Recall, PR-AUC ve toplam maliyet metriklerine göre karşılaştırılmıştır.

Model karşılaştırma sonuçları, farklı algoritmaların dolandırıcılık işlemlerini tespit etme başarısını ve yanlış alarm oranlarını analiz etmeye olanak sağlamıştır.

3.6 Feature Importance Analizi

Modelin karar mekanizmasını daha iyi anlamak amacıyla feature importance analizi gerçekleştirilmiştir. Bu analiz sayesinde dolandırıcılık tespiti üzerinde en fazla etkiye sahip olan değişkenler belirlenmiştir.

Random Forest ve XGBoost modelleri için hesaplanan feature importance değerleri incelenmiş ve dolandırıcılık tespiti üzerinde en etkili değişkenler analiz edilmiştir.

3.7 SHAP Model Açıklanabilirliği

Model tahminlerinin daha iyi yorumlanabilmesi için SHAP (SHapley Additive exPlanations) yöntemi kullanılmıştır. SHAP yöntemi, her bir değişkenin model tahminine yaptığı katkıyı hesaplayarak model kararlarının daha anlaşılır hale getirilmesini sağlar.

SHAP analizi ile:

- Modelin global feature importance değerleri
- Tek bir işlem için model tahminini etkileyen faktörler

İncelenmiştir.

3.8 Veri Görselleştirme

Elde edilen model sonuçları ve analizler Tableau kullanılarak görselleştirilmiştir. Tableau dashboard üzerinde aşağıdaki analizler sunulmuştur:

- Model comparison grafikleri
- Precision–Recall analizi
- Threshold–Cost ilişkisi
- Feature importance görselleştirmesi

Bu dashboard sayesinde model performanslarının ve karar eşiği optimizasyonunun görsel olarak analiz edilmesi sağlanmıştır.

4. Deneysel Sonuçlar (Results)

Bu bölümde çalışmada kullanılan makine öğrenmesi modellerinin performansları karşılaştırılmış ve maliyet duyarlı yaklaşımın sonuçları analiz edilmiştir. Modeller Precision, Recall, PR-AUC ve toplam maliyet (cost) metrikleri kullanılarak değerlendirilmiştir.

4.1 Model Karşılaştırması

Çalışma kapsamında Logistic Regression, Random Forest, Gradient Boosting, XGBoost ve LightGBM algoritmaları kullanılarak dolandırıcılık tespiti gerçekleştirilmiştir. Her model test veri seti üzerinde değerlendirilmiş ve maliyet tabanlı eşik optimizasyonu uygulanmıştır.

Elde edilen sonuçlar Tabloda gösterilmektedir.

	model	best_cost	recall	precision	pr_auc
0	RandomForest	12080.0	0.844595	0.683060	0.821481
3	XGBoost	12560.0	0.858108	0.381381	0.808035
1	Logistic	13460.0	0.831081	0.561644	0.704996
2	GradientBoosting	13470.0	0.824324	0.721893	0.599682
4	LightGBM	27980.0	0.804054	0.081118	0.065563

Tablo 1. Makine öğrenmesi modellerinin performans karşılaştırması

Tablo incelendiğinde Random Forest modelinin en düşük toplam maliyeti elde ettiği görülmektedir. Bu durum Random Forest modelinin dolandırıcılık işlemlerini yakalama başarısı ile yanlış alarm oranı arasında dengeli bir performans sunduğunu göstermektedir.

XGBoost modeli yüksek recall değeri elde etmesine rağmen düşük precision değeri nedeniyle daha fazla yanlış alarm üretmiştir. Logistic Regression modeli ise daha dengeli bir performans sunmasına rağmen Random Forest modeline kıyasla daha yüksek maliyet üretmiştir.

Gradient Boosting modeli precision açısından güçlü bir performans göstermesine rağmen PR-AUC değerinin daha düşük olması nedeniyle genel performansı sınırlı kalmıştır. LightGBM modeli ise çok yüksek recall değeri üretmiş ancak precision değerinin oldukça düşük olması nedeniyle maliyet açısından en zayıf model olmuştur.

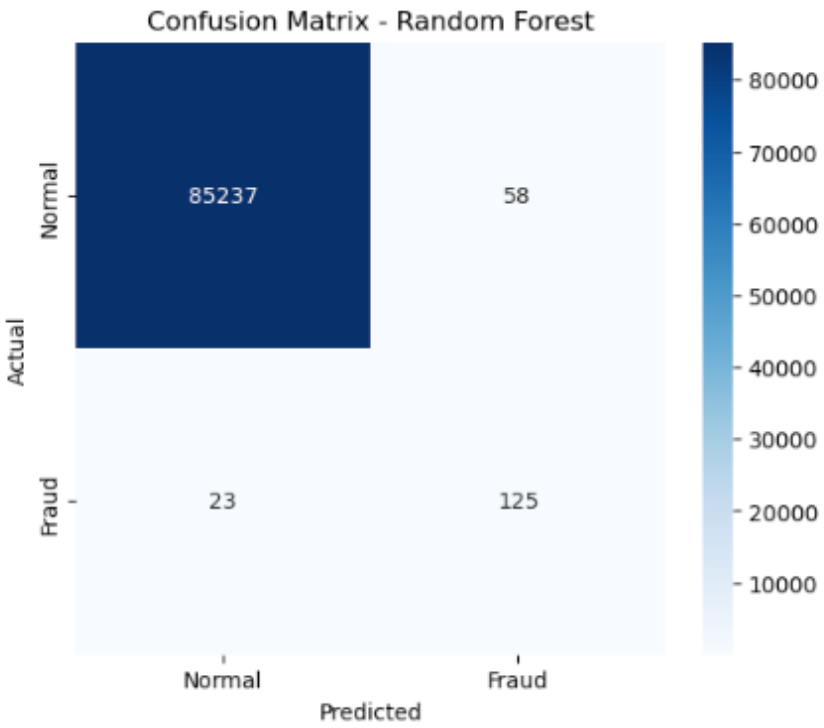

Şekil 1. Random Forest modeli için confusion matrix

Confusion matrix sonuçları incelendiğinde Random Forest modelinin dolandırıcılık işlemlerinin büyük bir bölümünü doğru şekilde tespit ettiği görülmektedir. Bununla birlikte model normal işlemlerin büyük çoğunluğunu da doğru sınıflandırmıştır. Elde edilen sonuçlar modelin hem dolandırıcılık işlemlerini yakalama başarısının yüksek olduğunu hem de yanlış alarm oranının kabul edilebilir seviyede kaldığını göstermektedir.

4.2 Karar Eşiği ve Maliyet Analizi

Dolandırıcılık tespiti problemlerinde modelin karar eşiği (threshold) performans üzerinde önemli bir etkiye sahiptir. Bu çalışmada farklı karar eşikleri için toplam maliyet hesaplanmış ve en düşük maliyet değerini veren eşik belirlenmiştir.

Şekil 2'de farklı modeller için karar eşiği ile toplam maliyet arasındaki ilişki gösterilmektedir.

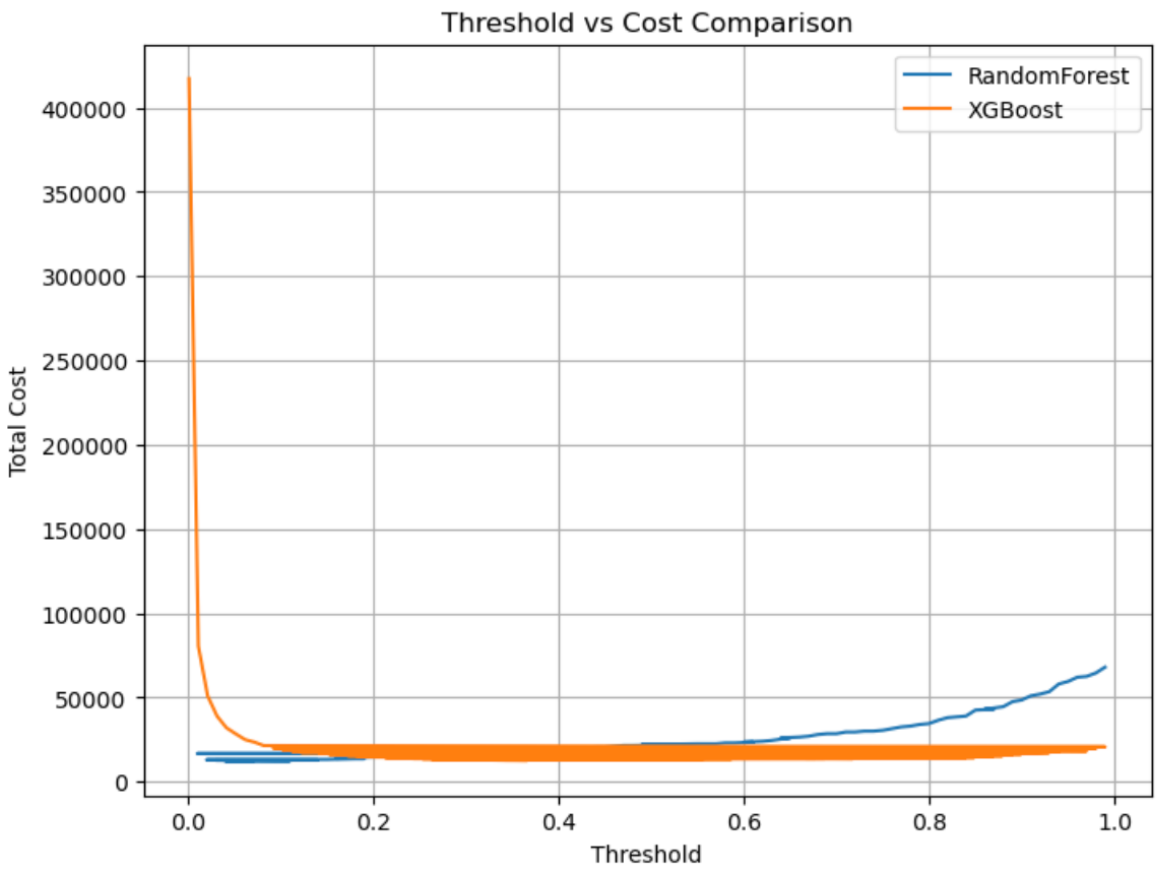

Şekil 2. Random Forest ve XGBoost modelleri için karar eşiği ile toplam maliyet arasındaki ilişki

Şekil 2'de Random Forest ve XGBoost modelleri için farklı karar eşikleri altında elde edilen toplam maliyet değerleri gösterilmektedir.

Grafik incelendiğinde düşük eşik değerlerinde modellerin çok fazla işlem için dolandırıcılık tahmini yaptığı ve bu nedenle yanlış pozitif sayısının arttığı görülmektedir. Bu durum toplam maliyetin yükselmesine neden olmaktadır. Eşik değeri arttıkça maliyet belirli bir noktaya kadar düşmekte, ancak eşik çok yükseldiğinde dolandırıcılık işlemlerinin kaçırılması nedeniyle maliyet tekrar artmaktadır. Bu nedenle maliyet açısından en uygun karar eşiğinin belirlenmesi kritik bir rol oynamaktadır.

```python
best_t_xgb = float(best_xgb["threshold"])
pred_xgb_best = (proba_xgb >= best_t_xgb).astype(int)

print("XGB Best Threshold:", best_t_xgb)
print("XGB Best Cost:", int(best_xgb["cost"]))
print(confusion_matrix(y_test, pred_xgb_best))
print(classification_report(y_test, pred_xgb_best, digits=4))
```

```
XGB Best Threshold: 0.3643061224489796
XGB Best Cost: 12560
[[85089   206]
 [   21   127]]
              precision    recall  f1-score   support

           0     0.9998    0.9976    0.9987     85295
           1     0.3814    0.8581    0.5281       148

    accuracy                         0.9973     85443
   macro avg     0.6906    0.9278    0.7634     85443
weighted avg     0.9987    0.9973    0.9979     85443
```

Bu nedenle dolandırıcılık tespit sistemlerinde doğru karar eşiğinin belirlenmesi model performansı açısından kritik bir öneme sahiptir.

4.3 Precision – Recall Analizi

Precision ve Recall metrikleri dolandırıcılık tespit problemlerinde model performansını değerlendirmek için önemli göstergelerdir.

Precision, modelin dolandırıcılık olarak tahmin ettiği işlemlerin ne kadarının gerçekten dolandırıcılık olduğunu gösterirken; Recall, gerçek dolandırıcılık işlemlerinin model tarafından ne kadarının tespit edildiğini göstermektedir.

Şekil 3'te modellerin Precision ve Recall değerleri karşılaştırılmıştır.

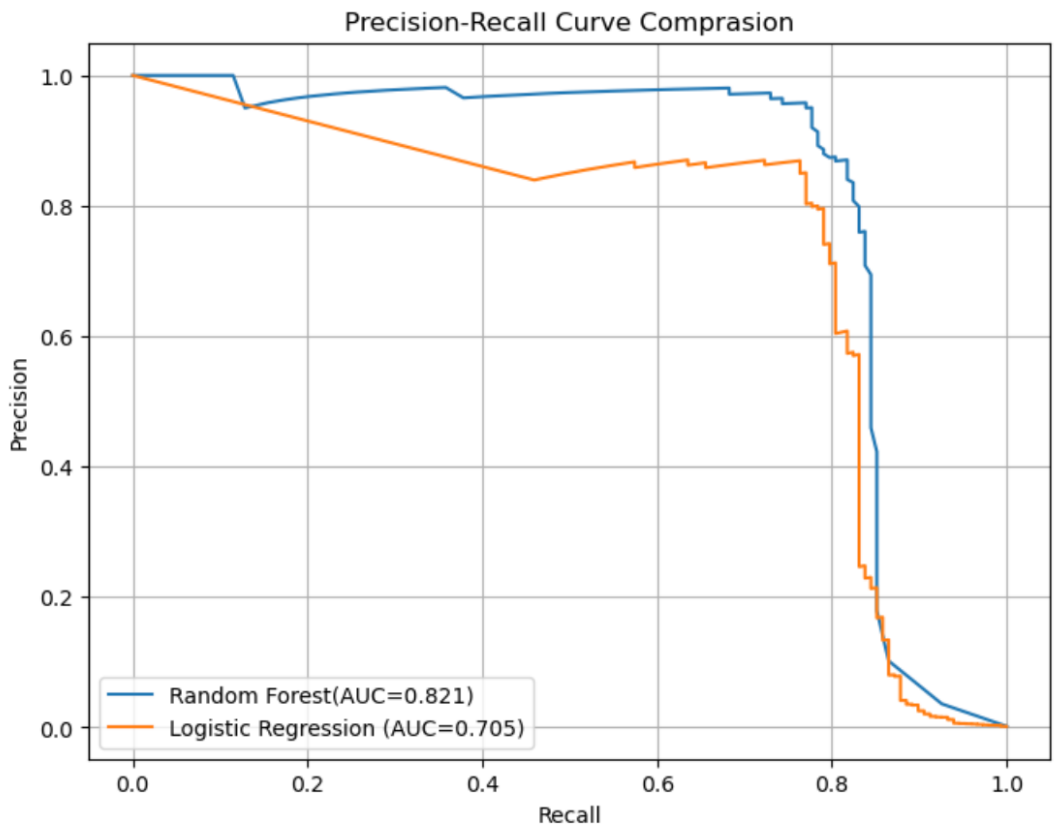

Şekil 3.Random Forest ve Logistic Regression modelleri için Precision–Recall eğrisi

Grafik incelendiğinde Random Forest modelinin Precision ve Recall arasında dengeli bir performans sunduğu görülmektedir. XGBoost modeli daha yüksek Recall değerine sahip olmasına rağmen düşük Precision değeri nedeniyle daha fazla yanlış alarm üretmektedir.

Dolandırıcılık tespiti sistemlerinde genellikle Recall değerinin yüksek olması tercih edilir çünkü dolandırıcılık işlemlerinin kaçırılması finansal kayıplara yol açabilir. Ancak Precision değerinin çok düşük olması da sistemin güvenilirliğini azaltabilir. Bu nedenle Precision ve Recall arasında dengeli bir performans elde edilmesi önemlidir.

4.4 Feature Importance Analizi

Modelin karar mekanizmasını daha iyi anlamak amacıyla feature importance analizi gerçekleştirilmiştir. Random Forest ve XGBoost modelleri kullanılarak değişkenlerin model tahminine olan katkıları incelenmiştir.

Analiz sonucunda dolandırıcılık tespiti üzerinde en etkili değişkenlerin V4, V14 ve V12 olduğu görülmüştür. Bu değişkenler model tahminlerini en fazla etkileyen özellikler olarak öne çıkmaktadır.

Veri setinde kullanılan PCA dönüşümü nedeniyle değişkenlerin doğrudan yorumlanması mümkün olmasa da bu değişkenlerin dolandırıcılık işlemlerini ayırt etmede önemli rol oynadığı görülmektedir.

Random Forest modeli için hesaplanan feature importance değerleri incelendiğinde V14, V4, V10 ve V12 değişkenlerinin model tahmininde önemli rol oynadığı görülmektedir.

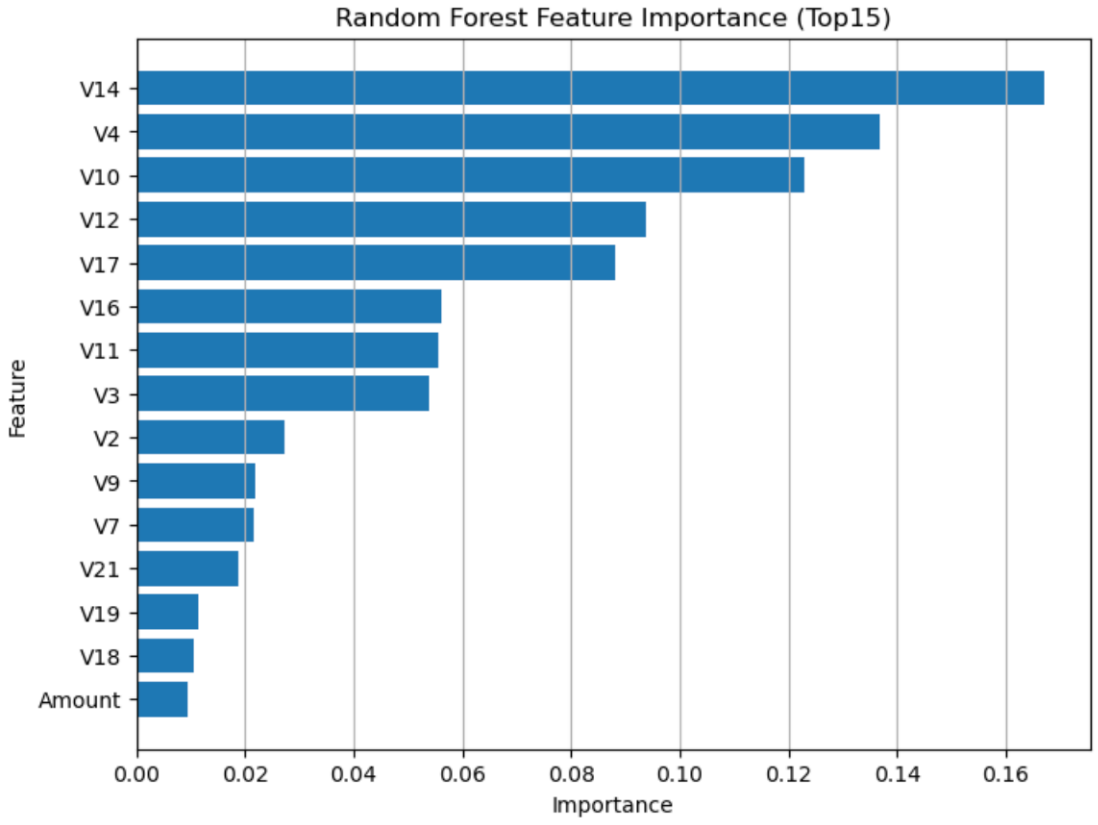

Şekil 4. **Random Forest modeli için feature importance grafiği**

```
top_xgb = feat_imp_xgb.head(15).sort_values("importance", ascending=True)

plt.figure(figsize=(8,6))
plt.barh(top_xgb["feature"], top_xgb["importance"])
plt.xlabel("Importance")
plt.ylabel("Feature")
plt.title("XGBoost Feature Importance (Top 15)")
plt.grid(True, axis="x")
plt.show()
```

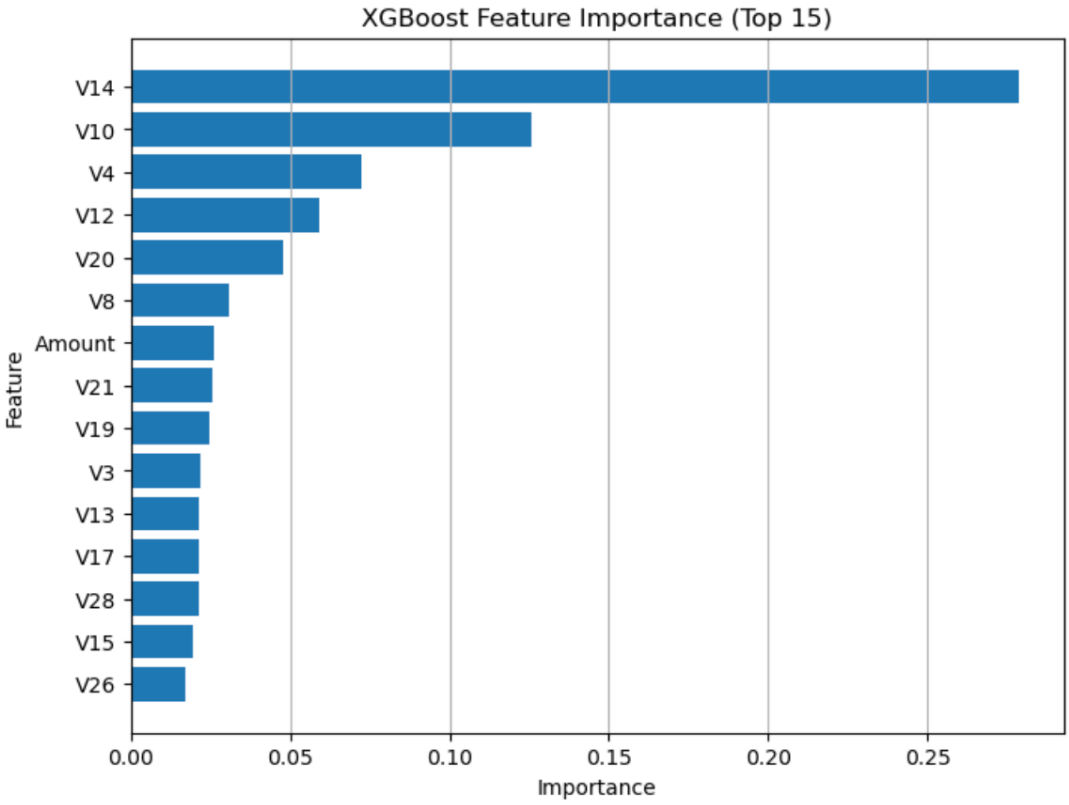

Şekil 5.XGBoost modeli için feature importance grafiği

Tablo 2 incelendiğinde Random Forest modeli için en önemli değişkenlerin V14, V4, V10 ve V12 olduğu görülmektedir. Bu değişkenler model tahminleri üzerinde en yüksek etkiye sahip özelliklerdir. Veri setinde kullanılan PCA dönüşümü nedeniyle değişkenlerin doğrudan yorumlanması mümkün olmasa da bu değişkenlerin dolandırıcılık işlemlerini ayırt etmede önemli rol oynadığı söylenebilir.

```
feat_imp = pd.DataFrame({
    "feature": X.columns,
    "importance": rf.feature_importances_,
    "model":"RandomForest"
}).sort_values("importance", ascending=False)
feat_imp.head(10)
```

	feature	importance	model
14	V14	0.167173	RandomForest
4	V4	0.136910	RandomForest
10	V10	0.123025	RandomForest
12	V12	0.093821	RandomForest
17	V17	0.088198	RandomForest
16	V16	0.056058	RandomForest
11	V11	0.055583	RandomForest
3	V3	0.053977	RandomForest
2	V2	0.027221	RandomForest
9	V9	0.021824	RandomForest

Tablo 2. Random Forest modeline göre en önemli özellikler

4.5 SHAP Model Açıklanabilirliği

Model tahminlerinin daha iyi anlaşılabilmesi için SHAP yöntemi kullanılmıştır. SHAP analizi sayesinde model tahminlerini etkileyen değişkenlerin katkıları detaylı olarak incelenmiştir.

SHAP sonuçları, global feature importance analizini desteklemekte ve özellikle V4, V14 ve V12 değişkenlerinin model kararlarında önemli bir rol oynadığını göstermektedir.

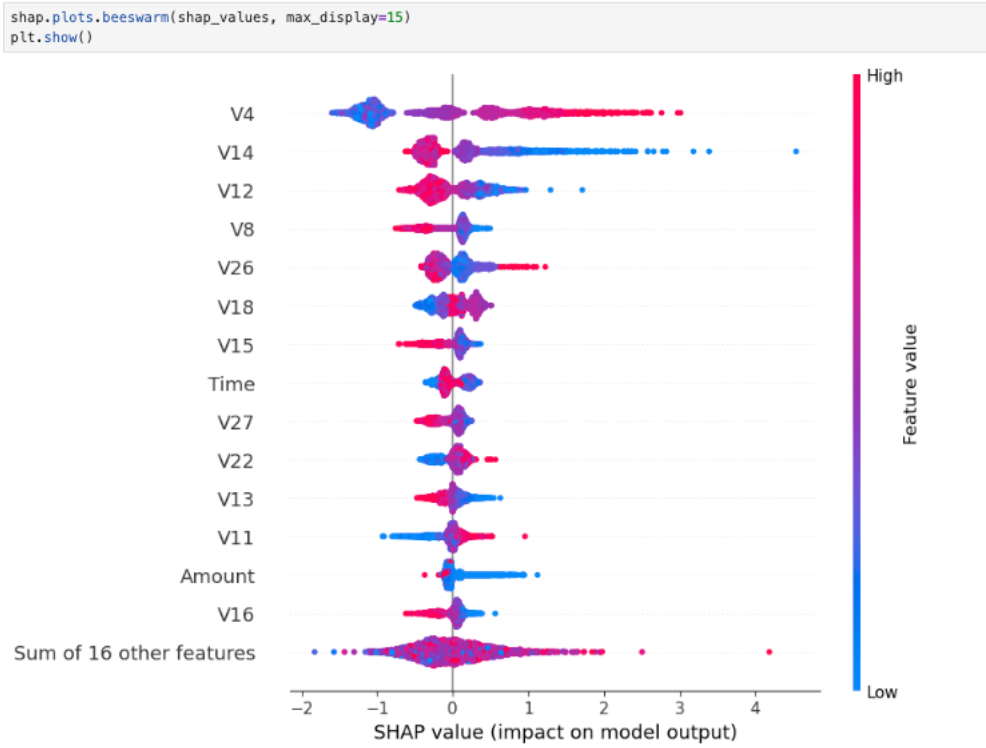

Şekil 6. SHAP global feature importance grafiği

```
shap.plots.waterfall(shap_values[fraud_idx], max_display=15)
plt.show()
```

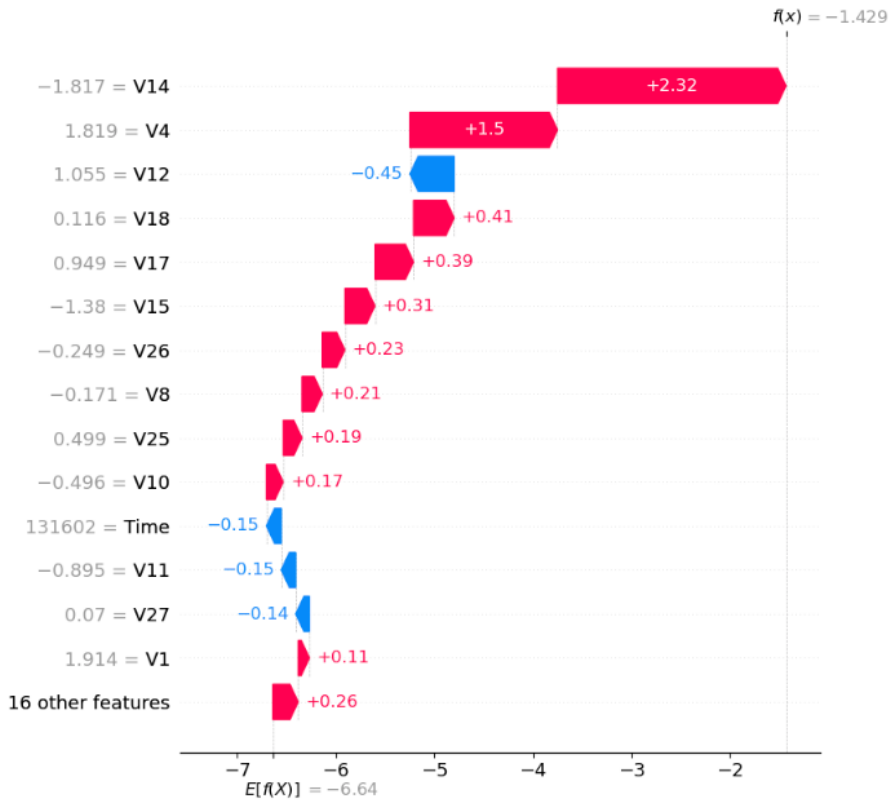

Şekil7.SHAP waterfall grafiği ile model tahmin açıklaması

```
shap.plots.bar(shap_values, max_display=15)
plt.show()
```

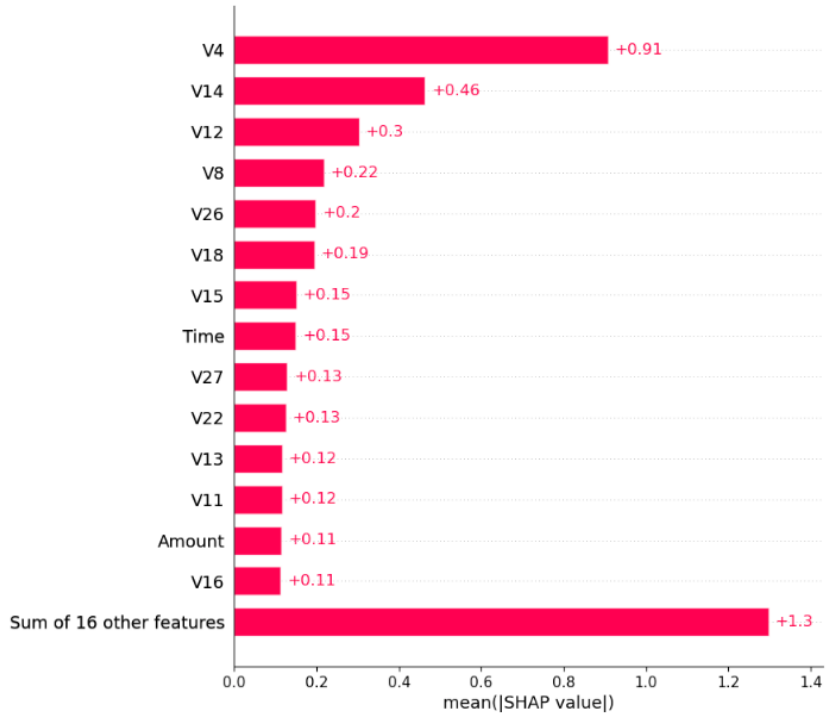

Şekil 8. SHAP summary plot

Ayrıca SHAP waterfall grafikleri kullanılarak tek bir işlem için model tahmininin hangi değişkenlerden etkilendiği görselleştirilmiştir. Bu analiz sayesinde model kararlarının daha şeffaf ve yorumlanabilir hale gelmesi sağlanmıştır.

4.6 Tableau Dashboard Analizi

Model sonuçlarının görsel olarak analiz edilebilmesi amacıyla Tableau kullanılarak interaktif bir dashboard geliştirilmiştir. Dashboard üzerinde aşağıdaki analizler sunulmuştur:

- Model comparison grafikleri
- Precision – Recall analizi
- Threshold – Cost ilişkisi
- Feature importance görselleştirmesi

Bu dashboard sayesinde farklı modellerin performansları ve maliyet optimizasyonu sonuçları kolaylıkla analiz edilebilmektedir.

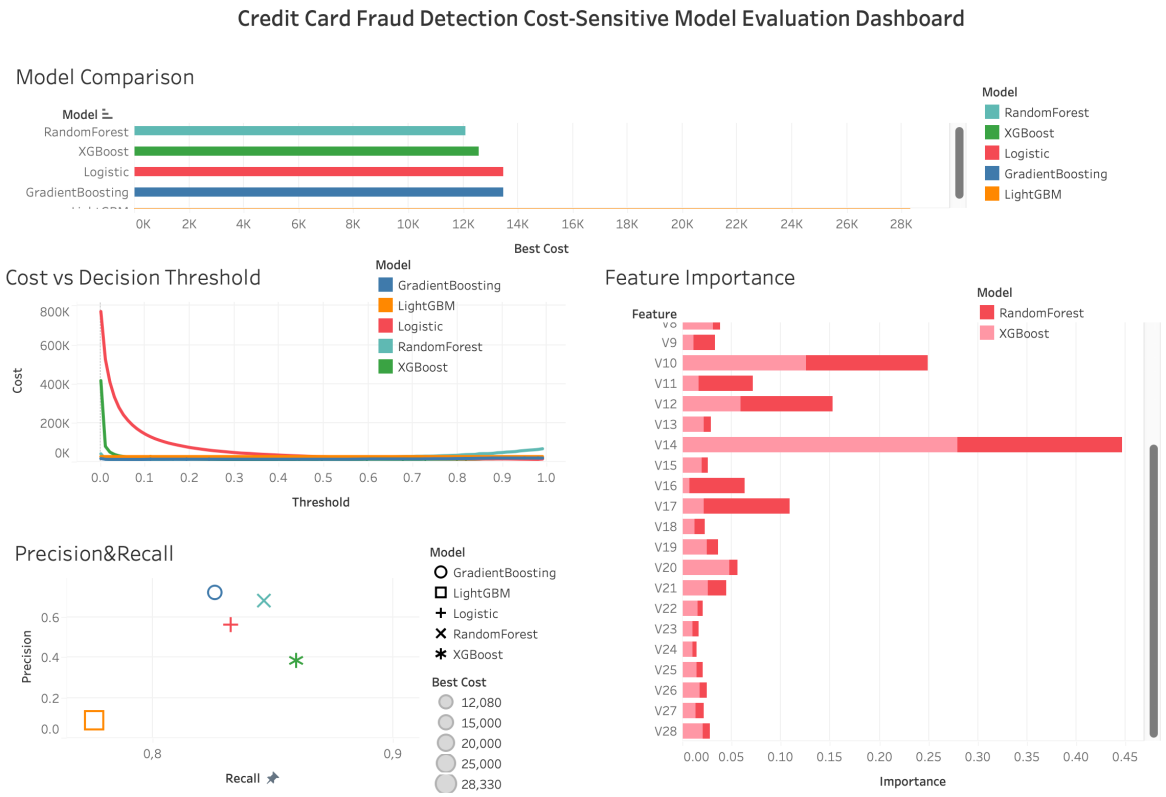

Şekil 9. Fraud detection model comparison dashboard

5. Sonuç (Conclusion)

Bu çalışmada kredi kartı dolandırıcılığı tespit problemi maliyet duyarlı bir makine öğrenmesi yaklaşımı kullanılarak ele alınmıştır. Finansal işlemlerden oluşan yüksek derecede dengesiz bir veri seti üzerinde farklı makine öğrenmesi algoritmaları eğitilmiş ve modellerin performansları çeşitli metrikler kullanılarak karşılaştırılmıştır. Çalışmada özellikle dolandırıcılık tespiti problemlerinde kritik öneme sahip olan **precision, recall, PR-AUC ve toplam maliyet (cost)** metrikleri dikkate alınmıştır.

Deneysel sonuçlar incelendiğinde **Random Forest modelinin toplam maliyet açısından en iyi performansı gösterdiği** görülmüştür. Random Forest modeli hem dolandırıcılık işlemlerini yakalama başarısı hem de yanlış alarm oranı açısından dengeli bir performans sergilemiştir. XGBoost modeli yüksek recall değerleri üretmesine rağmen düşük precision değeri nedeniyle daha fazla yanlış pozitif üretmiştir. Logistic Regression modeli ise daha basit bir model olmasına rağmen belirli bir performans sunmuş ancak maliyet açısından Random Forest modelinin gerisinde kalmıştır. Gradient Boosting ve LightGBM modelleri de değerlendirilmiş, ancak özellikle precision ve maliyet açısından daha sınırlı performans göstermiştir.

Çalışmanın önemli katkılarından biri **cost-based threshold optimization** yaklaşımının uygulanmasıdır. Dolandırıcılık tespit sistemlerinde yanlış negatif (False Negative) hatalarının finansal açıdan çok daha yüksek maliyetlere yol açtığı bilinmektedir. Bu nedenle sınıflandırma karar eşiği değiştirilerek toplam maliyetin minimize edilmesi amaçlanmıştır. Elde edilen sonuçlar, doğru karar eşiğinin belirlenmesinin model performansı üzerinde önemli bir etkisi olduğunu göstermektedir. Bu yaklaşım sayesinde dolandırıcılık işlemlerinin daha etkin bir şekilde tespit edilmesi mümkün hale gelmiştir.

Model sonuçlarının yorumlanabilirliğini artırmak amacıyla **feature importance analizi ve SHAP (SHapley Additive exPlanations)** yöntemi kullanılmıştır. SHAP analizi model kararlarının daha şeffaf hale getirilmesini sağlamış ve özellikle **V4, V14 ve V12 değişkenlerinin dolandırıcılık tespiti üzerinde önemli etkiler oluşturduğunu** ortaya koymuştur. Bu tür açıklanabilirlik yöntemleri finansal sistemlerde kullanılan makine öğrenmesi modellerinin güvenilirliğini artırmak açısından büyük önem taşımaktadır.

Çalışmada elde edilen sonuçlar ayrıca **Tableau kullanılarak geliştirilen interaktif bir dashboard** ile görselleştirilmiştir. Bu dashboard sayesinde farklı modellerin performansları, karar eşiği ile maliyet arasındaki ilişki ve feature importance analizleri görsel olarak incelenebilmiştir. Bu tür görselleştirme araçları, makine öğrenmesi sonuçlarının teknik olmayan kullanıcılar ve iş karar vericileri tarafından da daha kolay anlaşılmasını sağlamaktadır.

İş dünyası perspektifinden değerlendirildiğinde bu tür dolandırıcılık tespit sistemleri bankalar ve finans kuruluşları için önemli operasyonel avantajlar sağlamaktadır. Makine öğrenmesi tabanlı dolandırıcılık tespit sistemleri, şüpheli işlemleri erken aşamada tespit ederek finansal kayıpları azaltabilir ve risk yönetimi süreçlerini iyileştirebilir. Ayrıca maliyet duyarlı modelleme yaklaşımı sayesinde yanlış alarm oranı ile dolandırıcılık yakalama oranı arasında daha dengeli bir yapı kurulabilir.

Gelecekte yapılabilecek çalışmalar kapsamında veri setine ek özellikler eklenerek model performansı daha da artırılabilir. Ayrıca **deep learning tabanlı yöntemler**, **anomaly detection algoritmaları** veya **ensemble modeller** kullanılarak dolandırıcılık tespit sistemlerinin performansı geliştirilebilir. Bunun yanında gerçek zamanlı işlem verileri üzerinde çalışan **real-time fraud detection sistemleri** geliştirilmesi de önemli bir araştırma alanı olarak öne çıkmaktadır.

Sonuç olarak bu çalışma, maliyet duyarlı makine öğrenmesi yöntemlerinin kredi kartı dolandırıcılığı tespitinde etkili bir şekilde kullanılabileceğini göstermektedir. Elde edilen bulgular, doğru model seçimi ve karar eşiği optimizasyonunun dolandırıcılık tespit sistemlerinin performansı üzerinde kritik bir rol oynadığını ortaya koymaktadır.

6. Gelecek Çalışmalar (Future Work)

Bu çalışmada kredi kartı dolandırıcılığı tespit problemi maliyet duyarlı bir makine öğrenmesi yaklaşımı kullanılarak ele alınmış ve farklı makine öğrenmesi modellerinin performansları karşılaştırılmıştır. Elde edilen sonuçlar **Random Forest** modelinin toplam maliyet açısından en iyi performansı gösterdiğini ortaya koymuştur. Bununla birlikte dolandırıcılık tespiti alanı sürekli gelişen bir araştırma alanı olup gelecekte yapılabilecek çalışmalar ile model performansı daha da geliştirilebilir.

Öncelikle veri seti üzerinde **gelişmiş veri ön işleme ve özellik mühendisliği (feature engineering)** yöntemleri uygulanarak model performansı artırılabilir. Özellikle işlem davranışlarına dayalı yeni özellikler oluşturulması, kullanıcı işlem alışkanlıklarının analiz edilmesi ve zaman serisi özelliklerinin modele dahil edilmesi dolandırıcılık işlemlerinin daha doğru şekilde tespit edilmesine katkı sağlayabilir.

İkinci olarak çalışmada kullanılan klasik makine öğrenmesi algoritmalarına ek olarak **deep learning tabanlı yöntemler** araştırılabilir. Özellikle **Recurrent Neural Networks (RNN), Long Short-Term Memory (LSTM)** ve **Autoencoder tabanlı anomaly detection yöntemleri** finansal işlem verilerinde dolandırıcılık tespitinde kullanılabilecek güçlü yaklaşımlar arasında yer almaktadır. Bu tür modeller özellikle işlem sıraları ve kullanıcı davranışlarını analiz etmek açısından avantaj sağlayabilir.

Bunun yanında dolandırıcılık tespiti problemlerinde **ensemble öğrenme yöntemleri** ve model kombinasyonları da araştırılabilir. Birden fazla modelin çıktılarının birleştirilmesi sayesinde daha güçlü ve daha güvenilir tahminler elde edilebilir. Özellikle stacking veya blending gibi yöntemler farklı modellerin güçlü yönlerini bir araya getirmek açısından faydalı olabilir.

Bir diğer önemli araştırma alanı **gerçek zamanlı dolandırıcılık tespit sistemleri (real-time fraud detection)** geliştirilmesidir. Finansal kurumlar açısından dolandırıcılık işlemlerinin mümkün olan en kısa sürede tespit edilmesi kritik öneme sahiptir. Bu nedenle gelecekte

yapılacak çalışmalar, makine öğrenmesi modellerinin gerçek zamanlı işlem verileri üzerinde çalışabilecek şekilde optimize edilmesini hedefleyebilir.

Son olarak, model açıklanabilirliği ve güvenilirliği finans sektöründe büyük önem taşımaktadır. Bu nedenle gelecekte yapılacak çalışmalarda **model explainability yöntemleri** daha kapsamlı şekilde incelenebilir ve farklı açıklanabilir yapay zeka teknikleri kullanılarak model kararlarının daha şeffaf hale getirilmesi sağlanabilir. Bu tür yaklaşımlar, finans kuruluşlarının makine öğrenmesi modellerini operasyonel sistemlerde daha güvenle kullanmasına katkı sağlayacaktır.

Sonuç olarak, maliyet duyarlı makine öğrenmesi yaklaşımlarının dolandırıcılık tespit problemlerinde önemli avantajlar sunduğu görülmektedir. Gelecekte yapılacak çalışmalar ile veri analizi teknikleri, modelleme yöntemleri ve gerçek zamanlı sistem entegrasyonları geliştirilerek daha etkili dolandırıcılık tespit sistemleri oluşturulabilir.